



universidad
de león



Escuela de Ingenierías Industrial, Informática y Aeroespacial

GRADO EN INGENIERÍA INFORMÁTICA

Prácticas Externas

-

Informe mensual III

Desarrollo de técnicas de inteligencia artificial para luchar
contra el COVID-19

Autor: María García Girón

17 de diciembre, 2021



1. Descripción del trabajo desde el último informe

Como se mencionó en el último informe, tras terminar con la fase de formación, se comenzó con el proyecto final de detección de técnicas que permitan frenar la enfermedad del SARS-CoV-2.

Mi grupo, llamado Camadi, está formado por Diego González, Carlos Díez y María García. Tras realizar la reunión presencial en la empresa con todos los miembros del grupo, se decidió centrarnos en dos corrientes. La primera realizar un modelo para tratar imágenes de rostros con las mascarillas puestas de diversas formas. También decidimos realizar un modelo que pudiese tratar datos numéricos y categóricos, para detectar si una persona sufría la enfermedad.

Ambos conjuntos de datos son públicos y los podemos encontrar en la plataforma de Kaggle con la que trabajó anteriormente para las competiciones iniciales.

- ⇒ <https://www.kaggle.com/iamhungundji/covid19-symptoms-checker>
- ⇒ <https://www.kaggle.com/tapakah68/medical-masks-part1>

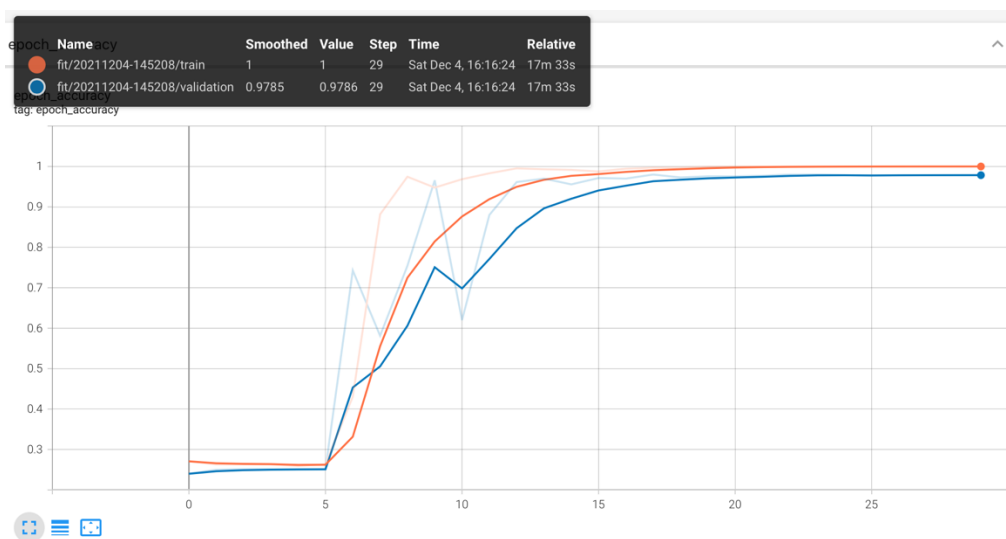
Se acordó comenzar primero con el tratamiento de las imágenes. Uno de los desafíos con los que nos encontramos fue el número masivo de datos con los que teníamos que tratar, ya que contábamos con 500 GB de imágenes. Como era impensable con los recursos con los que contábamos, se decidió escoger 10.000 imágenes.

Tras proceder con la carga de imágenes en el cuaderno, pasar las imágenes a un conjunto de vectores de píxeles y dividir el conjunto de entrenamiento, se empezó a crear una red convolucional. En el modelo se fueron añadiendo capas de dropout, batch normalization, convolucionales, pooling y densas.

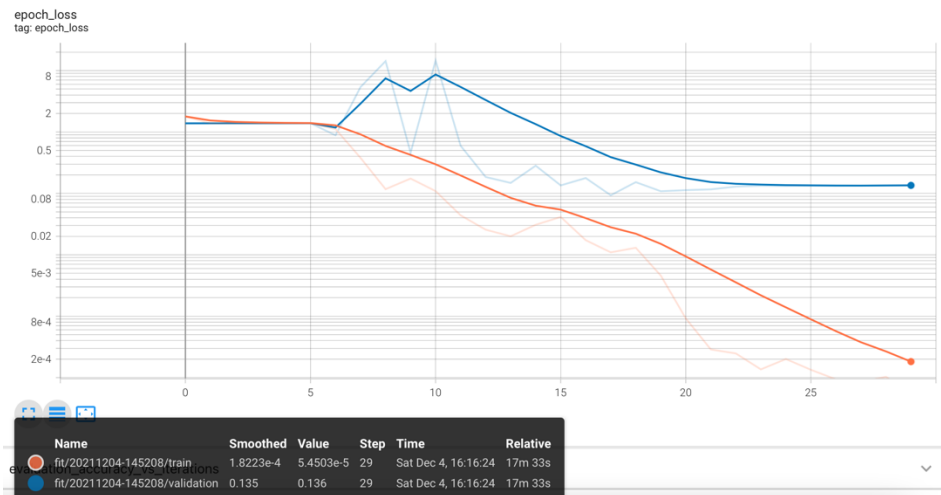
Este primer modelo funcionaba solo para el dataset de entrenamiento, por lo que se estaba produciendo overfitting, ya que intentaba entrenar con muchos parámetros (cerca de 148 millones). Para intentar reducirlo modificamos el tamaño de kernel, disminuimos capas de dropout y cambiamos el número de filtros para las capas convolucionales y densas.

Tras las modificaciones realizadas se consiguió un accuracy en entrenamiento de 1 y una función de pérdida de 0.0034. En validación el accuracy aumentó hasta un 0.86 y la función de pérdida un 0.3.

Finalmente, tras una reunión con el tutor de empresa se nos propuso probar con una técnica de Transfer Learning, es decir, entrenar con un modelo preentrenado. Se probó con el modelo Xception, VGG-16 e InceptionResNetV2. El modelo que mejor generalizaba para nuestro problema fue Xception. A continuación, se muestra la función de accuracy y pérdida entrenando con 5000 imágenes para ello se ha usado la funcionalidad de TensorBoard.



[Fig 1] Accuracy Modelo Xception



[Fig 2] Función Pérdida Modelo Xception

Otra de las funcionalidades que se probó fue pasar las imágenes a una escala de grises, pero no se vio mejora.

Finalmente, para este problema se realizó una pequeña aplicación en Python con la que acceder a la cámara de tu dispositivo y te mostrase si tenías la mascarilla bien puesta, por debajo de la nariz, por debajo de la barbilla o sin poner.

Tras terminar con el modelo de imágenes, se comenzó con el análisis de síntomas. En primer lugar, se realizó un análisis EDA de los datos. Como todas las columnas ya se encontraban con valores 0 o 1, no había demasiado trabajo que hacer en el preprocesado de datos.

Se crearon varios modelos como redes neuronales, random forest, support vector machines y XGBoost. Todos los modelos no eran capaces de generalizar correctamente. Tras realizar un estudio nos dimos cuenta que los datos no eran fiables.



Se trataban básicamente de permutaciones de las columnas. Por ejemplo, todos los síntomas a 1 (fiebre y tos) y salida de que no tiene enfermedad. Los datos supuestamente se basaban en un estudio de la Organización Mundial de la Salud, pero se puede ver fácilmente que no son adecuados para detectar la enfermedad de Covid.

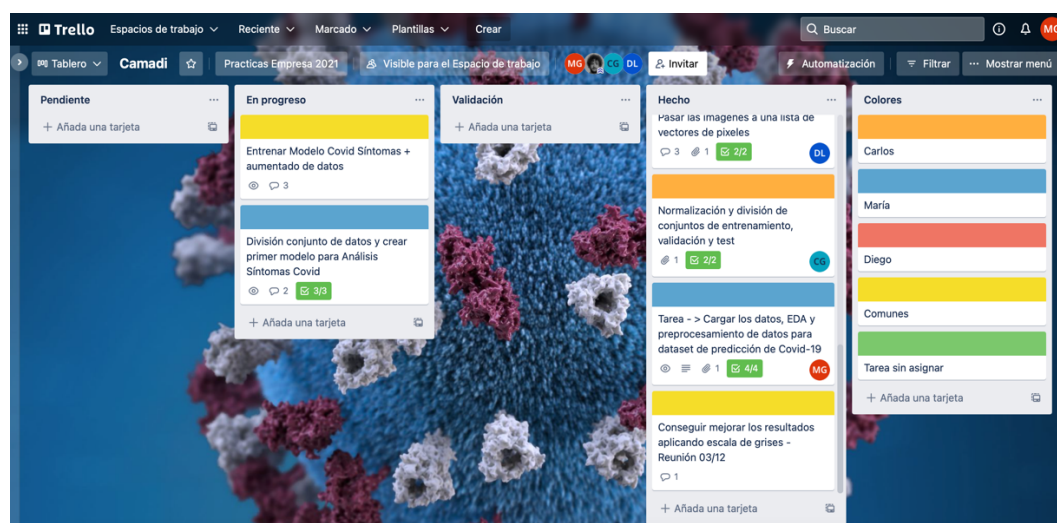
2. Planificación del trabajo

Se han realizado reuniones con los miembros del grupo para trabajar conjuntamente y repartir el trabajo necesario.

Las reuniones han sido los días:

- 26 de noviembre
- 30 de noviembre
- 3 de diciembre
- 9 de diciembre

Además, se han actualizado las tareas en el grupo Camadi de Trello. Esta es la visión de nuestro tablero actualmente:



[Fig 3] Tablero de trabajo y tareas



3. Descripción de los próximos pasos

El día 16 de diciembre se realizó la reunión con el tutor y se propusieron las siguientes alternativas para seguir:

- Probar con un sistema de detección de rostros en el dataset de imágenes para comprobar que se esa manera funcione mejor la aplicación realizada.
- Probar con un sistema de aprendizaje no supervisada como clustering en el dataset de análisis de síntomas.

Desde la empresa, nos han aconsejado no seguir con el dataset de análisis de síntomas ya que no es fiable. Además, se ha concluido que tras realizar estas tareas, comencemos a redactar la memoria de prácticas.